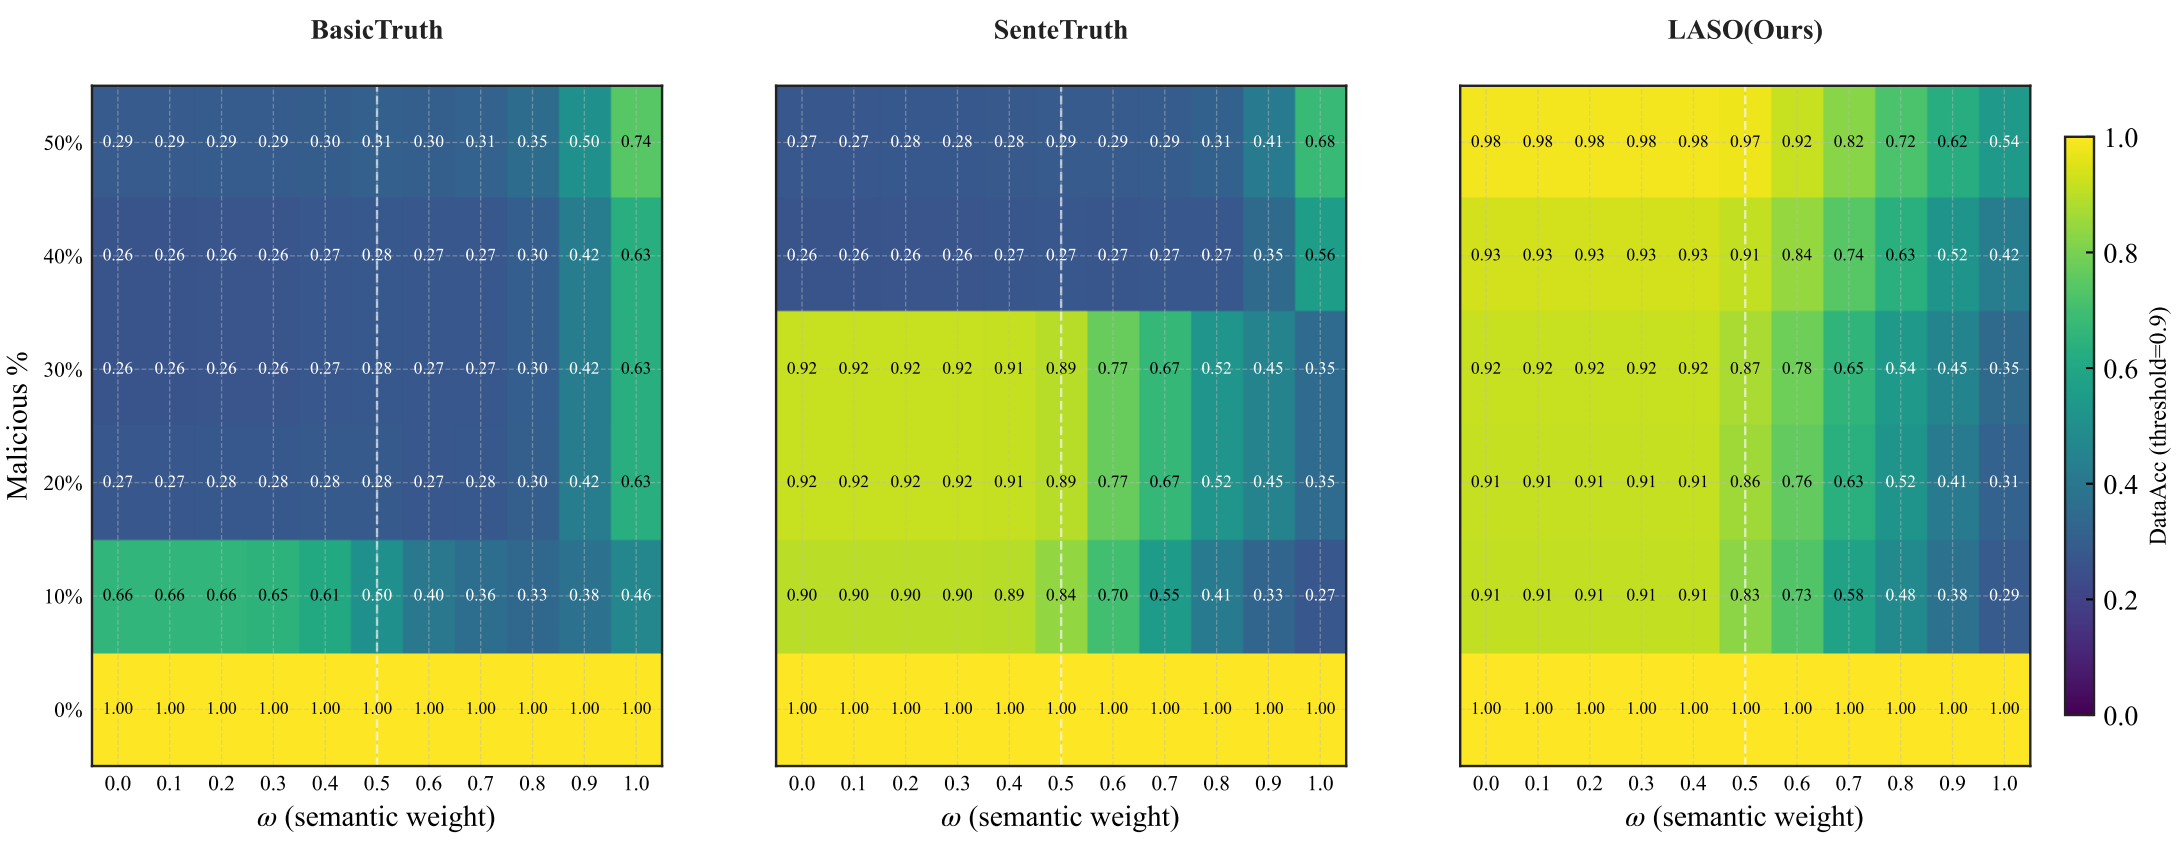
BasicTruth
SenteTruth
LASO(Ours)
Malicious %
50%
40%
30%
20%
10%
0%
0.29 0.29 0.29 0.29 0.30 0.31 0.30 0.31 0.35 0.50 0.74
0.26 0.26 0.26 0.26 0.27 0.28 0.27 0.27 0.30 0.42 0.63
0.26 0.26 0.26 0.26 0.27 0.28 0.27 0.27 0.30 0.42 0.63
0.27 0.27 0.28 0.28 0.28 0.28 0.27 0.28 0.30 0.42 0.63
0.66 0.66 0.66 0.65 0.61 0.50 0.40 0.36 0.33 0.38 0.46
1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00
0.27 0.27 0.28 0.28 0.28 0.29 0.29 0.29 0.31 0.41 0.68
0.26 0.26 0.26 0.26 0.27 0.27 0.27 0.27 0.27 0.35 0.56
0.92 0.92 0.92 0.92 0.91 0.89 0.77 0.67 0.52 0.45 0.35
0.92 0.92 0.92 0.92 0.91 0.89 0.77 0.67 0.52 0.45 0.35
0.90 0.90 0.90 0.90 0.89 0.84 0.70 0.55 0.41 0.33 0.27
1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00
0.98 0.98 0.98 0.98 0.98 0.97 0.92 0.82 0.72 0.62 0.54
0.93 0.93 0.93 0.93 0.93 0.91 0.84 0.74 0.63 0.52 0.42
0.92 0.92 0.92 0.92 0.92 0.87 0.78 0.65 0.54 0.45 0.35
0.91 0.91 0.91 0.91 0.91 0.86 0.76 0.63 0.52 0.41 0.31
0.91 0.91 0.91 0.91 0.91 0.83 0.73 0.58 0.48 0.38 0.29
1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00 1.00
0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
ω (semantic weight)
DataAcc (threshold=0.9)
1.0
0.8
0.6
0.4
0.2
0.0